

André E. Lazzaretti  
UTFPR/CPGEI



# Ementa

- Introdução à análise de padrões
- Modelos Lineares Generativos (Métodos estatísticos)
- Métodos de Otimização
- Modelos Lineares Discriminativos
- Modelos Não-Lineares
- Aprendizagem não-supervisionada
- Detecção de Novidades
- Extração de Características e Redução de Dimensionalidade
- Redes Neurais, Deep Learning e Convolutional Neural Networks
- Análise e Comparação de Desempenho
- Modelos de Markov (*Hidden Markov Models*) (\*)

# Calendário

- Semana 1 (hoje): Introdução à análise de padrões
- Semana 2: Métodos estatísticos parte 1
- Semana 3: Métodos estatísticos parte 2
- Semana 4: Métodos de otimização
- Semana 5: Modelos lineares
- Semana 6: Modelos não-lineares
- Semana 7: Análise e Comparação de Desempenho
- Semana 8: Aprendizagem não-supervisionada
- Semana 9: Detecção de Novidades
- Semana 10: Extração de Características e Redução de Dimensionalidade
- Semana 11: Redes Neurais e Deep Learning
- Semana 12: Modelos de Markov, apresentação das propostas e entrega dos exercícios

# Pré-requisitos

- Álgebra Linear;
- Probabilidade e Estatística;
- Cálculo Diferencial e Integral;
- Programação (Matlab, Python).








# Aulas

- Uso de slides para apresentação dos conceitos;
- Detalhamento de equações/deduções e resoluções de exercícios – Quadro ou com auxílio PC;
- Matlab/Octave!
- **Listas de exercícios para entrega** para facilitar compreensão – mais práticas, porém são colocados alguns pontos para deduções e soluções analíticas;

# Avaliação

- Entrega dos Exercícios propostos.
- Trabalho Final:
  - Reproduzir integralmente ou parcialmente um artigo;
  - Propor uma técnica de RP para um determinado problema;
  - Procurar algo relacionado com sua dissertação/tese.
  - Regras do Trabalho Final:
    - Individual;
    - Apresentar a proposta antes do final do trimestre para validação (por escrito);
    - Trabalho escrito no formato de artigo (Padrão IEEE – Conferência – mín. de quatro páginas) + apresentação a ser agendada durante o trimestre;
- Nota Final:
  - $0,3 \times \text{Notas dos Exercícios} + 0,1 \times \text{Apresentação da proposta} + 0,3 \times \text{Artigo do Trabalho Final} + 0,3 \times \text{Apresentação do Trabalho Final}$

# Bibliografia




# Aulas de Outras Universidades

- Andrew Ng (Stanford):
  - <http://www.andrewng.org/courses/>
  - [https://www.youtube.com/playlist?list=PLJ\\_CMb\\_wA6bT-n1W0mgOIYwccZ-j6gBXqE](https://www.youtube.com/playlist?list=PLJ_CMb_wA6bT-n1W0mgOIYwccZ-j6gBXqE)
- Nando de Freitas (UBC-Oxford):
  - <http://www.cs.ubc.ca/~nando/540-2013/lectures.html>



# Introdução

- Exemplo: diferenciar camelos de elefantes




KIMIA dataset

Para alguém que nunca viu esses animais antes (p.ex. criança de três-quatro anos). Ele(a) seria capaz de agrupar as figuras similares?

Se fossem apresentadas novas figuras e fossem dados nomes às classes, ele(a) conseguiria classificá-las?

# Introdução

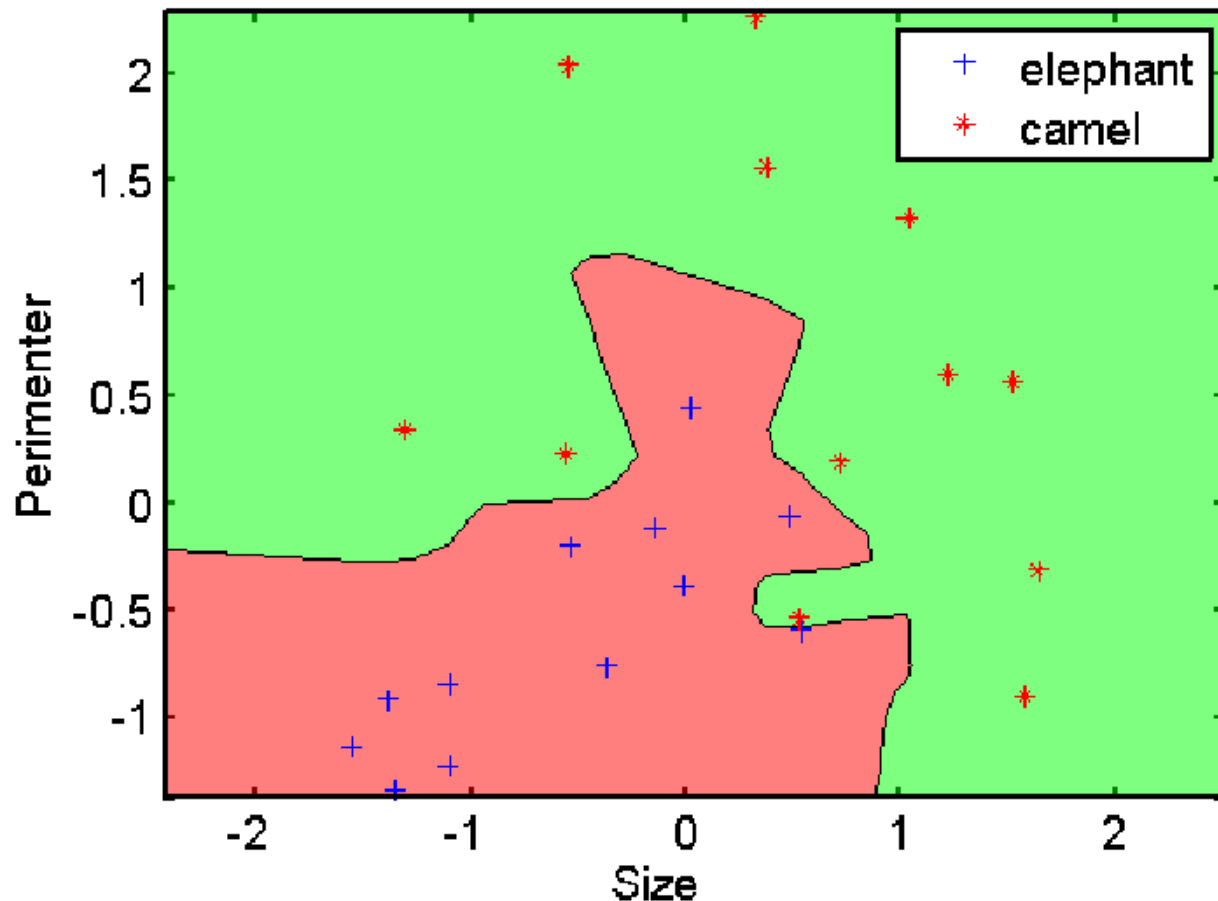
- Como poderíamos fazer o mesmo com um computador?
- Abordagem numérica → calcular similaridades;
- Area e Perímetro dos animais:



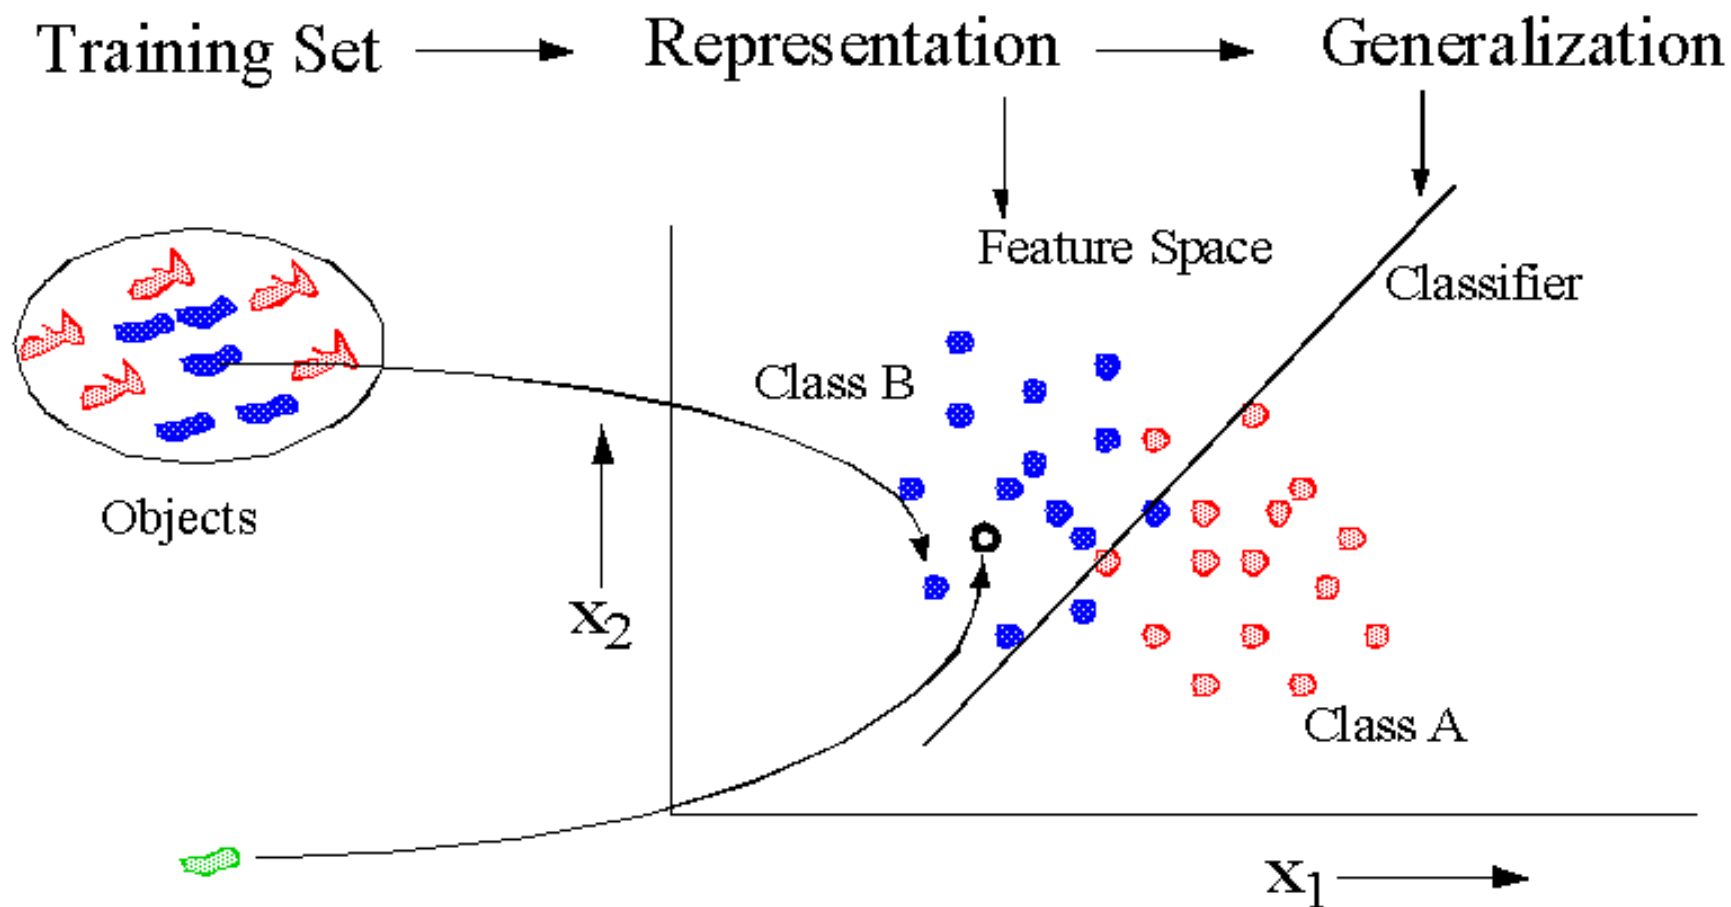
**Espaço de Características  
(Feature Space)**

# Introdução

- Com isso, pode-se criar um classificador (processo de aprendizagem por exemplos):




# Visão Geral




# Aprendizado Supervisionado x Não-Supervisionado

Supervised Learning




Unsupervised Learning




# Regressão

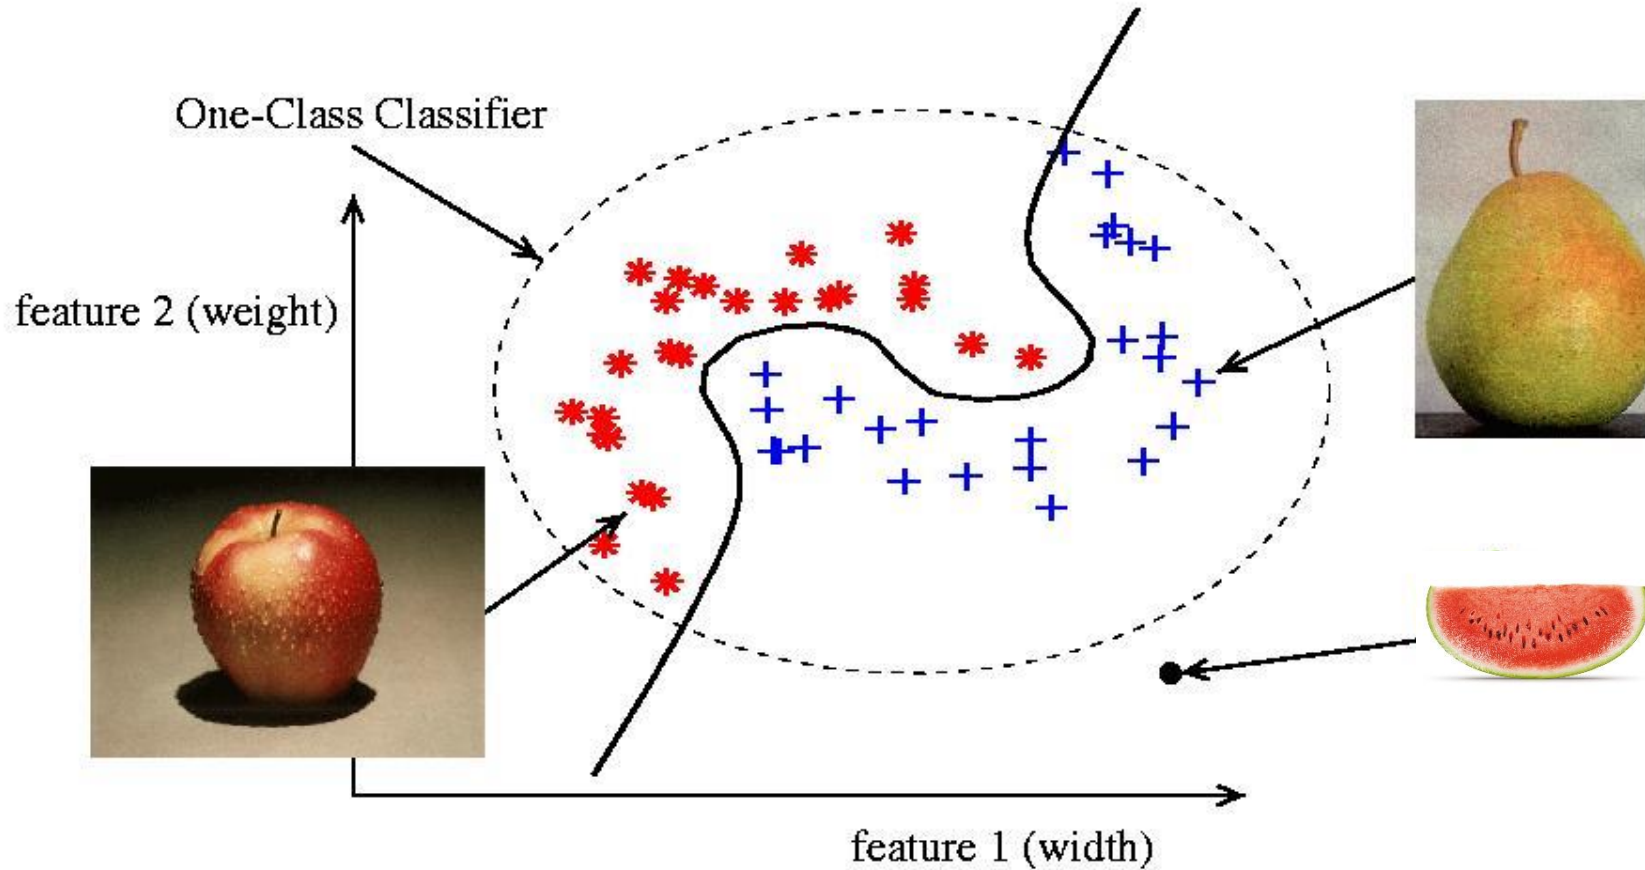
Classification



Regression



# Detecção de Novidades (one-class)




# Tecnologias já Disponíveis





# Amazon GO



# Conceitos Iniciais

- Probabilidade:
  - Incerteza é um conceito chave na área de reconhecimento de padrões/aprendizado de máquina.
  - **Aprendizado → redução de incerteza.**
  - Probabilidade de um evento é a fração de vezes que o evento ocorre em relação a um número total de tentativas, no limite em que o número de tentativas tende a infinito.
- Regras Básicas de Probabilidade:
  - Soma.
  - Produto.

# Leis Básicas de Probabilidade

**sum rule**

$$p(X) = \sum_Y p(X, Y)$$

**product rule**

$$p(X, Y) = p(Y|X)p(X).$$

*Bayes' theorem*





$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

$p(X, Y)$  é a probabilidade conjunta (probabilidade de X e Y)

$p(Y|X)$  é a probabilidade condicional (probabilidade de Y **dado** X)


$p(X)$  é a probabilidade marginal (probabilidade de X)

# Leis Básicas de Probabilidade



# Leis Básicas de Probabilidade

- Laranjas e Maças em duas caixas:




## Perguntas:

- 1) Qual a probabilidade de selecionar uma maçã?
- 2) **Dado que foi observada uma laranja, qual a probabilidade da caixa escolhida ser a azul?**

**Leis Básicas da Probabilidade!**

# Leis Básicas de Probabilidade

- Problema das Laranjas e Maçãs:



$$p(B = r) = 4/10$$

$$p(B = b) = 6/10$$

$$p(F = a|B = r) = 1/4$$

$$p(F = o|B = r) = 3/4$$

$$p(F = a|B = b) = 3/4$$

$$p(F = o|B = b) = 1/4.$$

$$p(B = r) + p(B = b) = 1$$

$$p(F = a|B = r) + p(F = o|B = r) = 1$$

$$p(F = a|B = b) + p(F = o|B = b) = 1$$

# Leis Básicas de Probabilidade

$$\begin{array}{ll} p(B = r) = 4/10 & p(F = a|B = r) = 1/4 \\ p(B = b) = 6/10 & p(F = o|B = r) = 3/4 \\ & p(F = a|B = b) = 3/4 \\ & p(F = o|B = b) = 1/4. \end{array}$$

- Qual a probabilidade de escolher maçã?

$$p(X) = \sum_Y p(X|Y)p(Y)$$

$$\begin{aligned} p(F = a) &= p(F = a|B = r)p(B = r) + p(F = a|B = b)p(B = b) \\ &= \frac{1}{4} \times \frac{4}{10} + \frac{3}{4} \times \frac{6}{10} = \frac{11}{20} \end{aligned}$$

$$p(F = o) = 1 - 11/20 = 9/20$$

# Leis Básicas de Probabilidade

$$p(B = r) = 4/10$$

$$p(B = b) = 6/10$$

$$p(F = o) = 1 - 11/20 = 9/20$$

$$p(F = a|B = r) = 1/4$$

$$p(F = o|B = r) = 3/4$$

$$p(F = a|B = b) = 3/4$$

$$p(F = o|B = b) = 1/4.$$


- Qual a probabilidade da caixa escolhida ser a vermelha, dado que a fruta selecionada é laranja?

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

$$p(B = r|F = o) = \frac{p(F = o|B = r)p(B = r)}{p(F = o)} = \frac{3}{4} \times \frac{4}{10} \times \frac{20}{9} = \frac{2}{3}.$$



# Função Densidade de Probabilidade





# Função Densidade de Probabilidade Gaussiana

- Caso unidimensional:

$$\mu = E[x] \equiv \int_{-\infty}^{+\infty} xp(x)dx$$

$$p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

$$\sigma^2 = E[(x - \mu)^2] \equiv \int_{-\infty}^{+\infty} (x - \mu)^2 p(x)dx$$



# Função Densidade de Probabilidade Gaussiana

- Caso multidimensional:


$$p(\mathbf{x}) = \frac{1}{(2\pi)^{l/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \Sigma^{-1} (\mathbf{x} - \boldsymbol{\mu})\right)$$

$$\boldsymbol{\mu} = E[\mathbf{x}]$$



$$\Sigma = E[(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T]$$

**2-D:**

$$\begin{aligned}\Sigma &= E \left[ \begin{bmatrix} x_1 - \mu_1 \\ x_2 - \mu_2 \end{bmatrix} \begin{bmatrix} x_1 - \mu_1, & x_2 - \mu_2 \end{bmatrix} \right] \\ &= \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}\end{aligned}$$




$$\Sigma = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$$



# Bernoulli distribution

- Bernoulli (pmf):



$$f(k; p) = \begin{cases} p & \text{if } k = 1, \\ 1 - p & \text{if } k = 0. \end{cases}$$

$$f(k; p) = p^k (1 - p)^{1-k} \quad \text{for } k \in \{0, 1\}.$$

# Referências

- Livro Pattern Classification – Duda/Hart;
- Livro Pattern Recognition and Machine Learning - Bishop;
- Aulas Prof. David M. J. Tax e Prof. Bob Duin – TU Delft.