


Aula 3 – Métodos de Otimização

André E. Lazzaretti

UTFPR/CPGEI





Otimização

- Por que otimização?
 - Em reconhecimento de padrões, frequentemente busca-se otimizar (maximizar ou minimizar) uma determinada função matemática (função custo, função de perda, função objetivo).
- Por exemplo:
 - Log-likelihood (da aula passada) → maximizar
 - Erro de Classificação → minimizar
- Estrutura geral: monta-se a função e realiza-se a otimização
- Otimização (em geral não-linear):
 - Sem restrições
 - Com restrições de igualdade
 - Com restrições de igualdade e desigualdade

Otimização sem restrições

$$\min_{\mathbf{x}} g(\mathbf{x}) = \max_{\mathbf{x}} [-g(\mathbf{x})]$$


- $g(\mathbf{x}) \rightarrow$ função objetivo
- $\mathbf{x} = [x_1, x_2, \dots, x_n] \rightarrow$ variáveis a serem otimizadas



Otimização sem restrições

$$\nabla g(\mathbf{x}) = \left[\frac{\partial g(\mathbf{x})}{\partial x_1}, \frac{\partial g(\mathbf{x})}{\partial x_2}, \dots, \frac{\partial g(\mathbf{x})}{\partial x_n} \right]^t$$


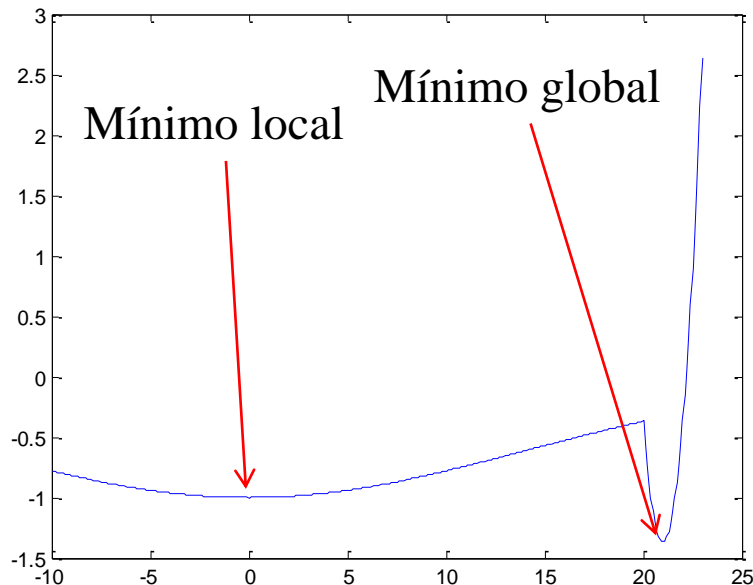
- $\nabla g(\mathbf{x}) \rightarrow$ gradiente de $g(\mathbf{x})$
 - Fornece a direção de maior inclinação (variação) de $g(\mathbf{x})$
 - Direção inversa de $\nabla g(\mathbf{x})$:
Direção de máximo decrescimento



Otimização sem restrições

- Pontos de mínimo
 - Mínimo global
 - \mathbf{x}^* é um mínimo global se


$$g(\mathbf{x}^*) \leq g(\mathbf{x}), \forall \mathbf{x} \in \mathcal{R}^n$$



Otimização sem restrições

- Mínimo local: $g(\mathbf{x}^*) \leq g(\mathbf{x}), \forall \mathbf{x} \in \mathcal{R}^n \mid \|\mathbf{x}^* - \mathbf{x}\| < \varepsilon$
- Condições de otimalidade:
 - **Condição necessária:** se $g(\mathbf{x})$ for continuamente diferenciável (condição de primeira ordem):

$$\nabla g(\mathbf{x}) \Big|_{\mathbf{x}=\mathbf{x}^*} = \begin{bmatrix} \partial g(\mathbf{x})/\partial x_1 \\ \vdots \\ \partial g(\mathbf{x})/\partial x_n \end{bmatrix} \Big|_{\mathbf{x}=\mathbf{x}^*} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$$



Otimização sem restrições


- **Condição suficiente:** se cada elemento de $\nabla^2 g(\mathbf{x})$ for uma função contínua, $\nabla^2 g(\mathbf{x})$ calculada para $\mathbf{x} = \mathbf{x}^*$ deve ser positiva definida para que \mathbf{x}^* seja um ponto de mínimo local (Condição de segunda ordem):

$$\nabla^2 g(\mathbf{x}) = \mathbf{H}(\mathbf{x}) = \begin{bmatrix} \partial^2 g(\mathbf{x}) / \partial x_1^2 & \cdots & \partial^2 g(\mathbf{x}) / \partial x_1 \partial x_n \\ \vdots & \ddots & \vdots \\ \partial^2 g(\mathbf{x}) / \partial x_1 \partial x_n & \cdots & \partial^2 g(\mathbf{x}) / \partial x_n^2 \end{bmatrix}$$


- Uma matriz Ω é positiva definida se todos os autovalores λ_i , $i = 1, 2, \dots, n$, de Ω são positivos.
- Gradiente nulo: ponto de sela, máximo ou mínimo.
 - Negativa definida – ponto de máximo
 - Autovalores positivos e negativos: ponto de sela

Otimização sem restrições

- Condições necessária e suficiente para que \mathbf{x}^* seja um ponto de mínimo local
 1. $\nabla g(\mathbf{x})|_{\mathbf{x}=\mathbf{x}^*} = \mathbf{0}$
 2. $\mathbf{H}(\mathbf{x})$ calculada para $\mathbf{x} = \mathbf{x}^*$ deve ser positiva definida
- Se $g(\mathbf{x})$ for convexa e \mathbf{x}^* satisfaz a condição de primeira ordem, então \mathbf{x}^* é um ponto de mínimo global



Função convexa: todos os mínimos locais são mínimos globais(*).



Como Resolver Otimização sem Restrições

- Na prática utiliza-se: $\nabla g(\mathbf{x}) = \mathbf{0}$
- Essa solução é viável quando $\nabla g(\mathbf{x}) = \mathbf{0}$ forma um sistema linear de equações;
- Caso isso não seja possível (sistema não-linear de equações) \rightarrow alternativas;
- Alternativa - Métodos iterativos:
 - Descida em gradiente;
 - Método de Newton.

Otimização sem restrições

- Descida em gradiente
 - Método de otimização numérica para minimização de $g(\mathbf{x})$
 - A partir de um estado inicial \mathbf{x}^0 , busca novos estados na direção de máximo decrescimento da função:
 - Direção inversa ao gradiente

$$\mathbf{x}^k = \mathbf{x}^{k-1} - \alpha \nabla g(\mathbf{x}) \Big|_{\mathbf{x}=\mathbf{x}^{k-1}}$$





- Subida em gradiente

$$\mathbf{x}^k = \mathbf{x}^{k-1} + \alpha \nabla g(\mathbf{x}) \Big|_{\mathbf{x}=\mathbf{x}^{k-1}}$$

Descida em Gradiente

- Ideia Geral:

$$\mathbf{x}^k = \mathbf{x}^{k-1} - \alpha \nabla g(\mathbf{x}) \Big|_{\mathbf{x}=\mathbf{x}^{k-1}}$$




Método de Newton

- Altera-se o passo do algoritmo:

$$\mathbf{x}^k = \mathbf{x}^{k-1} - \left[\mathbf{H}(\mathbf{x}) \Big|_{\mathbf{x}=\mathbf{x}^{k-1}} \right]^{-1} \nabla g(\mathbf{x}) \Big|_{\mathbf{x}=\mathbf{x}^{k-1}} \quad \text{ou} \quad \theta_{k+1} = \theta_k - \mathbf{H}_k^{-1} \mathbf{g}_k$$

- Esse método é derivado assumindo uma aproximação de segunda ordem (através da série de Taylor) da função no ponto em questão:
- Exercício – verificar!**



Exemplo – fminunc.m

Nonlinear programming solver.

Finds the minimum of a problem specified by

$$\min_x f(x)$$

where $f(x)$ is a function that returns a scalar.

x is a vector or a matrix; see [Matrix Arguments](#).

Syntax

```
x = fminunc(fun,x0)
x = fminunc(fun,x0,options)
```

Outra opção:

minimize.m - escrita por
Carl E. Rasmussen
(University of Cambridge)

<http://learning.eng.cam.ac.uk/carl/code/minimize/>

Minimize the function $f(x) = 3x_1^2 + 2x_1x_2 + x_2^2 - 4x_1 + 5x_2$.

Write an anonymous function that calculates the objective.

```
fun = @(x)3*x(1)^2 + 2*x(1)*x(2) + x(2)^2 - 4*x(1) + 5*x(2);
```

Call `fminunc` to find a minimum of `fun` near `[1,1]`.

```
x0 = [1,1];
[x,fval] = fminunc(fun,x0);
```

`fminunc` can be faster and more reliable when you provide derivatives.

$$f(x) = 100(x_2 - x_1^2)^2 + (1 - x_1)^2,$$

which has gradient

$$\nabla f(x) = \begin{bmatrix} -400(x_2 - x_1^2)x_1 - 2(1 - x_1) \\ 200(x_2 - x_1^2) \end{bmatrix}.$$

```
function [f,g] = rosenbrockwithgrad(x)
% Calculate objective f
f = 100*(x(2) - x(1)^2)^2 + (1-x(1))^2;

if nargin > 1 % gradient required
    g = [-400*(x(2)-x(1)^2)*x(1)-2*(1-x(1));
         200*(x(2)-x(1)^2)];
end
```

```
function [f,g] = rosenbrockwithgrad(x)
```

```
% Calculate objective f
```

```
f = 100*(x(2) - x(1)^2)^2 + (1-x(1))^2;
```

```
if nargin > 1 % gradient required
```

```
    g = [-400*(x(2)-x(1)^2)*x(1)-2*(1-x(1));
```

```
         200*(x(2)-x(1)^2)];
```

```
end
```

```
options = optimoptions('fminunc','Algorithm','trust-region','SpecifyObjectiveGradient',true);
```

```
problem.options = options;
```

```
problem.x0 = [-1,2];
```

```
problem.objective = @rosenbrockwithgrad;
```

```
problem.solver = 'fminunc';
```

```
x = fminunc(problem);
```

Otimização com restrições

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a (s.a.)

$$\omega_i(\mathbf{x}) = 0, i = 1, 2, \dots, N_i$$

$$g_i(\mathbf{x}) \leq 0, i = 1, 2, \dots, N_d$$

- $\omega_i(\mathbf{x}) \rightarrow$ restrições de igualdade
 - $N_i \rightarrow$ número de restrições de igualdade
- $g_i(\mathbf{x}) \rightarrow$ restrições de desigualdade
 - $N_d \rightarrow$ número de restrições de desigualdade
- Região viável \rightarrow definida pelas funções $\omega_i(\mathbf{x})$ e $g_i(\mathbf{x})$

Otimização com restrições

- Exemplo:

$$\min_{x_1, x_2} f(x_1, x_2) = 0,25x_1^2 + x_2^2$$

sa

$$x_1 + x_2 = 5$$

- Na forma padrão,

$$\min_{x_1, x_2} f(x_1, x_2) = 0,25x_1^2 + x_2^2$$

sa

$$\omega(\mathbf{x}) = 5 - x_1 - x_2 = 0$$


Otimização com restrições

- Exemplo:

$$\min_{x_1, x_2} f(x_1, x_2) = 0,25x_1^2 + x_2^2$$

sa

$$\omega(\mathbf{x}) = 5 - x_1 - x_2 = 0$$




Otimização com restrições

- Exemplo:

$$\min_{x_1, x_2} f(x_1, x_2) = 0,25x_1^2 + x_2^2$$

sa

$$\omega(\mathbf{x}) = 5 - x_1 - x_2 = 0$$



Otimização com restrições


- Exemplo:

$$\min_{x_1, x_2} f(x_1, x_2) = 0,25x_1^2 + x_2^2$$

sa

$$\omega(\mathbf{x}) = 5 - x_1 - x_2 = 0$$

- Componentes não-nulas de $\nabla f(\mathbf{x})$ na direção de $\omega(\mathbf{x})$




Otimização com restrições

- Exemplo: $\min_{x_1, x_2} f(x_1, x_2) = 0,25x_1^2 + x_2^2$

sa

$$\omega(\mathbf{x}) = 5 - x_1 - x_2 = 0$$



Otimização com restrições

- Exemplo:

$$\min_{x_1, x_2} f(x_1, x_2) = 0,25x_1^2 + x_2^2$$

sa

$$\omega(\mathbf{x}) = 5 - x_1 - x_2 = 0$$

- No ponto ótimo, $\nabla f(\mathbf{x})$ é perpendicular a $\omega(\mathbf{x})$
 - Os gradientes de $f(\mathbf{x})$ e de $\omega(\mathbf{x})$ estão alinhados

$$\nabla f(\mathbf{x}) + \lambda \nabla \omega(\mathbf{x}) = \mathbf{0}$$

- Princípio matemático do método dos multiplicadores de *Lagrange*

Otimização com restrições

- Exemplo:

$$\min_{x_1, x_2} f(x_1, x_2) = 0,25x_1^2 + x_2^2$$

sa

$$\omega(\mathbf{x}) = 5 - x_1 - x_2 = 0$$

- Funcional *Lagrangeano*

$$L(x_1, x_2, \lambda) = f(x_1, x_2) + \lambda \omega(x_1, x_2)$$

- $\lambda \rightarrow$ multiplicador de *Lagrange*

Otimização com restrições

- Exemplo:

$$\min_{x_1, x_2} f(x_1, x_2) = 0,25x_1^2 + x_2^2$$

sa

$$\omega(\mathbf{x}) = 5 - x_1 - x_2 = 0$$

- Para o exemplo,

$$L(x_1, x_2, \lambda) = f(x_1, x_2) + \lambda \omega(x_1, x_2)$$

$$L(x_1, x_2, \lambda) = 0,25x_1^2 + x_2^2 + \lambda(5 - x_1 - x_2)$$

Otimização com restrições

- Exemplo:
 - Para o exemplo,

$$L(x_1, x_2, \lambda) = 0,25x_1^2 + x_2^2 + \lambda(5 - x_1 - x_2)$$
$$\begin{cases} \frac{\partial}{\partial x_1} L(x_1, x_2, \lambda) = 0,5x_1 - \lambda = 0 \\ \frac{\partial}{\partial x_2} L(x_1, x_2, \lambda) = 2x_2 - \lambda = 0 \\ \frac{\partial}{\partial \lambda} L(x_1, x_2, \lambda) = 5 - x_1 - x_2 = 0 \end{cases} \Rightarrow \begin{cases} x_1^* = 4 \\ x_2^* = 1 \\ \lambda = 2 \end{cases}$$

Otimização com restrições

- Para problemas incluindo restrições de desigualdade, para que \mathbf{x}^* seja um ponto de mínimo, além da condição de primeira ordem $\nabla L(\mathbf{x}^*, \lambda) = \mathbf{0}$, é necessário que \mathbf{x}^* atenda as condições de *Karush-Kuhn-Tucker* (KKT):

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a (s.a.)

$$\omega_i(\mathbf{x}) = 0, i = 1, 2, \dots, N_i$$

$$g_i(\mathbf{x}) \leq 0, i = 1, 2, \dots, N_d$$

$$L(\mathbf{x}, \lambda, \mu) = f(\mathbf{x}) + \sum_{i=1}^{N_i} \lambda_i \omega_i(\mathbf{x}) + \sum_{i=1}^{N_d} \mu_i g_i(\mathbf{x})$$

Otimização com restrições

$$L(\mathbf{x}, \boldsymbol{\lambda}, \boldsymbol{\mu}) = f(\mathbf{x}) + \sum_{i=1}^{N_i} \lambda_i \omega_i(\mathbf{x}) + \sum_{i=1}^{N_d} \mu_i g_i(\mathbf{x})$$

- Condições KKT necessárias para que \mathbf{x}^* seja um ponto de mínimo:

$$1) \frac{\partial}{\partial x_i} L(\mathbf{x}^*, \boldsymbol{\lambda}^*, \boldsymbol{\mu}^*) = 0, i = 1, 2, \dots, n$$

$$2) \omega_i(\mathbf{x}^*) = 0, i = 1, 2, \dots, N_i$$

$$3) g_i(\mathbf{x}^*) \leq 0, i = 1, 2, \dots, N_d$$

$$4) \begin{cases} \mu_i^* g_i(\mathbf{x}^*) = 0 \\ \mu_i^* \geq 0 \end{cases}, i = 1, 2, \dots, N_d$$

Lembrando que:

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a (s.a.)

$$\omega_i(\mathbf{x}) = 0, i = 1, 2, \dots, N_i$$

$$g_i(\mathbf{x}) \leq 0, i = 1, 2, \dots, N_d$$

Otimização com restrições

- Exemplo $\min_{x_1, x_2} f(x_1, x_2) = 0,25x_1^2 + x_2^2$
sa
 $x_1 + x_2 = 5$
 $x_1 + 0,2x_2 \leq 3$

- Na forma padrão,

$$\min_{x_1, x_2} f(x_1, x_2) = 0,25x_1^2 + x_2^2$$

sa

$$\omega(x_1, x_2) = 5 - x_1 - x_2 = 0$$

$$g(x_1, x_2) = x_1 + 0,2x_2 - 3 \leq 0$$

Otimização com restrições


- Exemplo

$$\min_{x_1, x_2} f(x_1, x_2) = 0,25x_1^2 + x_2^2$$

sa

$$\omega(x_1, x_2) = 5 - x_1 - x_2 = 0$$

$$g(x_1, x_2) = x_1 + 0,2x_2 - 3 \leq 0$$



Otimização com restrições

- Exemplo
 - Calculando o *Lagrangeano*:

$$L(x_1, x_2, \lambda, \mu) = f(x_1, x_2) + \lambda \omega(x_1, x_2) + \mu g(x_1, x_2)$$

$$L(x_1, x_2, \lambda, \mu) = 0,25x_1^2 + x_2^2 + \lambda(5 - x_1 - x_2) + \mu(x_1 + 0,2x_2 - 3)$$

- Condições KKT:

$$1) \begin{cases} \frac{\partial}{\partial x_1} L(\mathbf{x}^*, \lambda^*, \mu^*) = 0,5x_1 - \lambda + \mu = 0 \\ \frac{\partial}{\partial x_2} L(\mathbf{x}^*, \lambda^*, \mu^*) = 2x_2 - \lambda + 0,2\mu = 0 \end{cases}$$

Otimização com restrições

- Exemplo

$$L(x_1, x_2, \lambda, \mu) = f(x_1, x_2) + \lambda \omega(x_1, x_2) + \mu g(x_1, x_2)$$

$$L(x_1, x_2, \lambda, \mu) = 0,25x_1^2 + x_2^2 + \lambda(5 - x_1 - x_2) + \mu(x_1 + 0,2x_2 - 3)$$

- Condições KKT:

$$2) \omega_1(\mathbf{x}^*) = 5 - x_1 - x_2 = 0$$

$$3) g_1(\mathbf{x}^*) = x_1 + 0,2x_2 - 3 \leq 0$$

$$4) \begin{cases} \mu^* g_1(\mathbf{x}^*) = \mu(x_1 + 0,2x_2 - 3) = 0 \\ \mu \geq 0 \end{cases}$$

Otimização com restrições

- Exemplo
 - Condições KKT:

$$\begin{aligned} 1) & \begin{cases} \frac{\partial}{\partial x_1} L(\mathbf{x}^*, \lambda^*, \mu^*) = 0,5x_1 - \lambda + \mu = 0 \\ \frac{\partial}{\partial x_2} L(\mathbf{x}^*, \lambda^*, \mu^*) = 2x_2 - \lambda + 0,2\mu = 0 \end{cases} \\ 2) & \omega_1(\mathbf{x}^*) = 5 - x_1 - x_2 = 0 \\ 3) & g_1(\mathbf{x}^*) = x_1 + 0,2x_2 - 3 \leq 0 \\ 4) & \begin{cases} \mu \geq 0 \\ \mu^* g_1(\mathbf{x}^*) = \mu(x_1 + 0,2x_2 - 3) = 0 \end{cases} \end{aligned}$$

▪Equações lineares

▪Inequações

▪Equação não-linear

Otimização com restrições

- Exemplo

- Condições KKT:

- Se $\mu = 0$:
$$\begin{cases} 0,5x_1 - \lambda = 0 \\ 2x_2 - \lambda = 0 \\ 5 - x_1 - x_2 = 0 \end{cases} \Rightarrow \begin{cases} \mu' = 0 \\ x_1' = 4 \\ x_2' = 1 \\ \lambda' = 2 \end{cases}$$

$$3) g_1(\mathbf{x}') \Big|_{x_1=x_1'; x_2=x_2'} = x_1' + 0,2x_1' - 3 = 1,2 \neq 0$$

- Violada a restrição de desigualdade
 - \mathbf{x}' não é ponto de mínimo

Otimização com restrições

- Exemplo

- Se $\mu > 0$:
$$\begin{cases} \mu^* g_1(\mathbf{x}^*) = \mu(x_1 + 0, 2x_2 - 3) = 0 \\ \mu \geq 0 \end{cases} \Rightarrow x_1 + 0, 2x_2 - 3 = 0$$

$$\begin{cases} 0,5x_1 - \lambda + \mu = 0 \\ 2x_2 - \lambda + 0,2\mu = 0 \\ 5 - x_1 - x_2 = 0 \\ x_1 + 0,2x_2 - 3 = 0 \end{cases} \Rightarrow \begin{cases} \mu'' = 4,6875 \\ x_1'' = 2,5 \\ x_2'' = 2,5 \\ \lambda'' = 5,9375 \end{cases}$$

$$g_1(\mathbf{x}'')|_{x_1=x_1''; x_2=x_2''} = x_1'' + 0,2x_2'' - 3 = 0 \leq 0$$

- Restrição de desigualdade atendida

- Restrição ativa

- \mathbf{x}'' é ponto de mínimo

Dificuldade: KKT não fornecem uma metodologia para obtenção de \mathbf{x}^*

Exemplo – fmincon.m

fmincon

Find minimum of constrained nonlinear multivariable function

Nonlinear programming solver.

Finds the minimum of a problem specified by

$$\min_x f(x) \text{ such that } \begin{cases} c(x) \leq 0 \\ ceq(x) = 0 \\ A \cdot x \leq b \\ Aeq \cdot x = beq \\ lb \leq x \leq ub, \end{cases}$$

Convex and nonconvex problems!

b and beq are vectors, A and Aeq are matrices, $c(x)$ and $ceq(x)$ are functions that return vectors, and $f(x)$ is a function that returns a scalar. $f(x)$, $c(x)$, and $ceq(x)$ can be nonlinear functions.

x , lb , and ub can be passed as vectors or matrices; see [Matrix Arguments](#).

Syntax

```
x = fmincon(fun,x0,A,b)
x = fmincon(fun,x0,A,b,Aeq,beq)
x = fmincon(fun,x0,A,b,Aeq,beq,lb,ub)
x = fmincon(fun,x0,A,b,Aeq,beq,lb,ub,nonlcon)
x = fmincon(fun,x0,A,b,Aeq,beq,lb,ub,nonlcon,options)
```

Find the minimum value of Rosenbrock's function when there are both a linear inequality constraint and a linear equality constraint.

Set the objective function `fun` to be Rosenbrock's function.

```
fun = @(x)100*(x(2)-x(1)^2)^2 + (1-x(1))^2;
```

Find the minimum value starting from the point $[0.5, 0]$, constrained to have $x(1) + 2x(2) \leq 1$ and $2x(1) + x(2) = 1$.

- Express the linear inequality constraint in the form $A \cdot x \leq b$ by taking $A = [1, 2]$ and $b = 1$.
- Express the linear equality constraint in the form $Aeq \cdot x = beq$ by taking $Aeq = [2, 1]$ and $beq = 1$.

```
x0 = [0.5, 0];
A = [1, 2];
b = 1;
Aeq = [2, 1];
beq = 1;
x = fmincon(fun,x0,A,b,Aeq,beq)
```

Problema: geralmente computacionalmente caro para problemas de reconhecimento de padrões. Métodos custosos — de

Problemas de Otimização Convexa

- Para problemas de otimização convexa, as condições KKT são necessárias e suficientes para caracterizar \mathbf{x}^* como um ponto de mínimo. Método mais “simples”: **DUALIDADE!**
- Problemas convexos:

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a (s.a.)

$$\omega_i(\mathbf{x}) = 0, i = 1, 2, \dots, N_i$$

$$g_i(\mathbf{x}) \leq 0, i = 1, 2, \dots, N_d$$

- Função objetivo convexa $\rightarrow f(\mathbf{x})$ **convexa**
- Restrições de desigualdade **convexas** $\rightarrow g_i(\mathbf{x})$ convexa
- Restrições de igualdade são **funções afins** $\rightarrow \omega_j(\mathbf{x})$
- Funções afins: $f(\mathbf{x}) = \mathbf{a}\mathbf{x} + b$

Dualidade

- Representação Dual de Wolfe:

Problema Original:

$$\min_{\mathbf{x}} f(\mathbf{x})$$

sujeito a (s.a.)

$$\omega_i(\mathbf{x}) = 0, i = 1, 2, \dots, N_i$$

$$g_i(\mathbf{x}) \leq 0, i = 1, 2, \dots, N_d$$

Valor ótimo \mathbf{p}^* (primal)

\equiv

$$\max_{\lambda, \mu} \left[\min_{\mathbf{x}} L(\mathbf{x}, \lambda, \mu) \right]$$

$$s.t.: \lambda \geq 0$$

$$\mu \geq 0$$

$$\nabla_{\mathbf{x}} L(\mathbf{x}, \lambda, \mu) = \mathbf{0}$$

Valor ótimo \mathbf{d}^* (dual)

Exemplo

- Problema:

$$\begin{array}{ll}\text{minimize} & x_1^2 + x_2 \\ & x \in \mathbb{R}^2 \\ \text{subject to} & 2x_1 + x_2 \geq 4 \\ & x_2 \geq 1.\end{array}$$

- Na forma padrão:

$$\begin{array}{ll}\text{minimize} & x_1^2 + x_2 \\ & x \in \mathbb{R}^2 \\ \text{subject to} & 4 - 2x_1 - x_2 \leq 0 \\ & 1 - x_2 \leq 0.\end{array}$$

Exemplo

- Lagrangeano:

$$\mathcal{L}(x, \alpha) = x_1^2 + x_2 + \alpha_1(4 - 2x_1 - x_2) + \alpha_2(1 - x_2)$$

- Representação de Wolfe:

$$\frac{\partial}{\partial x_1} \mathcal{L}(x, \alpha) = 2x_1 - 2\alpha_1 = 0 \quad \Longrightarrow \quad x_1 = \alpha_1$$

$$\frac{\partial}{\partial x_2} \mathcal{L}(x, \alpha) = 1 - \alpha_1 - \alpha_2 = 0$$

Exemplo

- Reescrevendo o Lagrangeano:

$$\mathcal{L}(x, \alpha) = x_1^2 + x_2 + \alpha_1(4 - 2x_1 - x_2) + \alpha_2(1 - x_2)$$

- Sendo: $x_1 = \alpha_1$

$$\left[\alpha_1^2 + x_2 + \alpha_1(4 - 2\alpha_1 - x_2) + \alpha_2(1 - x_2) \right]$$

$$\left[-\alpha_1^2 + 4\alpha_1 + \alpha_2 + x_2(1 - \alpha_1 - \alpha_2) \right]$$

- Sendo: $1 - \alpha_1 - \alpha_2 = 0$

$$\mathcal{L}(x, \alpha) = -\alpha_1^2 + 4\alpha_1 + \alpha_2$$

Exemplo

- Na representação de Wolfe:

$$\begin{array}{ll}\text{maximize} & -\alpha_1^2 + 4\alpha_1 + \alpha_2 \\ \text{subject to} & \alpha_1 \geq 0 \\ & \alpha_2 \geq 0 \\ & 1 - \alpha_1 - \alpha_2 = 0\end{array}$$

- Resulta em um problema de otimização quadrático com restrições mais simples (sempre convexo).

Exemplo – quadprog.m

1. Enter the coefficient matrices:

```
H = [1 -1; -1 2];  
f = [-2; -6];  
A = [1 1; -1 2; 2 1];  
b = [2; 2; 3];  
lb = zeros(2,1);
```

$$A \cdot x \leq b,$$
$$Aeq \cdot x = beq,$$
$$lb \leq x \leq ub.$$

2. Set the options to use the 'interior-point-convex' algorithm with no display:

```
options = optimoptions('quadprog',...  
    'Algorithm','interior-point-convex','Display','off');
```

3. Call quadprog:

```
[x,fval,exitflag,output,lambda] = ...  
    quadprog(H,f,A,b,[],[],lb,[],[],options);
```

4. Examine the final point, function value, and exit flag:

```
x,fval,exitflag
```

```
x =  
    0.6667  
    1.3333  
fval =  
   -8.2222  
exitflag =  
         1
```

5. An exit flag of 1 means the result is a local minimum. Because H is a positive definite matrix, this problem is convex, so the minimum is a global minimum. You can see H is positive definite by noting all its eigenvalues are positive:

```
eig(H)  
ans =  
    0.3820
```

Solve a simple quadratic programming problem:

find values of x that minimize $f(x) = \frac{1}{2}x_1^2 + x_2^2 - x_1x_2 - 2x_1 - 6x_2$,

subject to

$$\begin{aligned}x_1 + x_2 &\leq 2 \\ -x_1 + 2x_2 &\leq 2 \\ 2x_1 + x_2 &\leq 3 \\ 0 &\leq x_1, 0 \leq x_2.\end{aligned}$$

In matrix notation this is $f(x) = \frac{1}{2}x^T H x + f^T x$,

where $H = \begin{bmatrix} 1 & -1 \\ -1 & 2 \end{bmatrix}$, $f = \begin{bmatrix} -2 \\ -6 \end{bmatrix}$, $x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$.

Resumo

- Condições de otimalidade:
 - Primeira ordem: gradiente nulo
 - Segunda ordem: autovalores da matriz Hessiana
- Otimização sem restrições (**fminuncon.m**):
 - Descida em Gradiente
 - Método de Newton (aproximação quadrática).
- Otimização com restrições de igualdade:
 - Lagrangeano $\rightarrow \nabla L = 0$
- Otimização com restrições de igualdade e desigualdade:
 - Condições: KKT (necessárias e suficientes \rightarrow convexo)
 - Possibilidade: **fmincon.m** \rightarrow complexidade
 - Convexo (necessárias e suficientes \rightarrow convexo) **quadprog.m**:
 - Dualidade de Wolfe \rightarrow Programação Quadrática

Sequência “Típica”

- Definir o problema (classificação, regressão, clustering, etc);

$$J(\mathbf{w}) = \sum_{i=1}^N (y_i - \mathbf{x}_i^T \mathbf{w})^2 \equiv \sum_{i=1}^N e_i^2$$

- Escrever o problema na forma de um problema de otimização, cujas variáveis são os parâmetros do classificador, por exemplo:

$$\hat{\mathbf{w}} = \arg \min_{\mathbf{w}} J(\mathbf{w})$$

- Escolher um método adequado para resolução do problema de otimização:

$$\frac{\partial J(\mathbf{w})}{\partial \mathbf{w}} = \mathbf{0} \longrightarrow \hat{\mathbf{w}} = (X^T X)^{-1} X^T \mathbf{y}$$

- Utilizar os parâmetros para realizar novas estimativas.

Referências

- Livro Convex Optimization (Boyd)
- Aulas Professor Nando de Freitas (UBC/Oxford)
- Aulas Professor Andrew Ng (Stanford)
- Aulas Professor Stephen Boyd (Stanford)
- Aulas Professor Vitor Hugo Ferreira (UFF)
- Livro Power Generation, Operation and Control – Allen Wood